Árboles de decisión

Inés Asenjo González, Marta González Mariño, Raúl Martínez Aguilar, Juan Sánchez Lafuente

23 de marzo de 2026

Contenido

1. Definición de árbol de decisión
2. Datos
3. Tipos de árboles de decisión
4. Ventajas y desventajas
5. Formulación del algoritmo
6. Criterios de clasificación
7. Coste computacional
8. Implementación con Scikit-learn
9. Algunos algoritmos de árboles de decisión
10. Metodología y reparto de trabajo
11. Referencias

Árboles de decisión

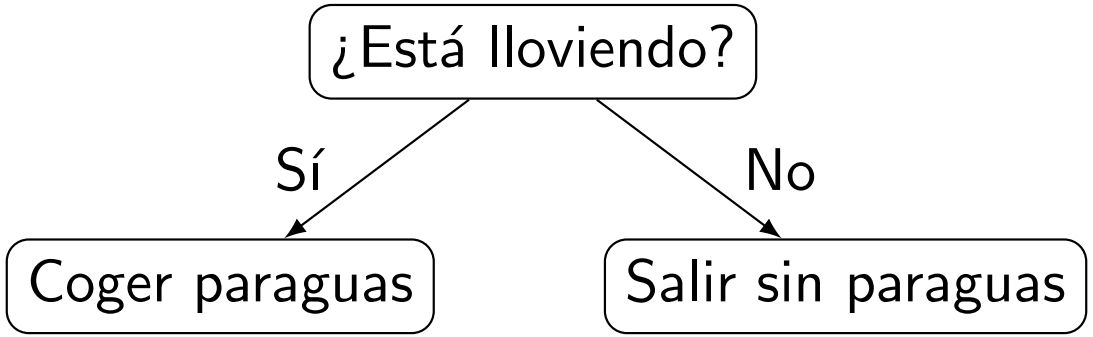

Datos

sepal length	**sepal width**	**petal length**	**petal width**	**species**
5.1	3.5	1.4	0.2	setosa
4.9	3.0	1.4	0.2	setosa
5.7	3.0	4.2	1.2	versicolor
5.7	2.9	4.2	1.3	versicolor
6.7	3.0	5.2	2.3	virginica
6.3	2.5	5.0	1.9	virginica

Cuadro: 4 observaciones del dataset Iris. Unidades de longitud: cm

Tipos de árboles de decisión

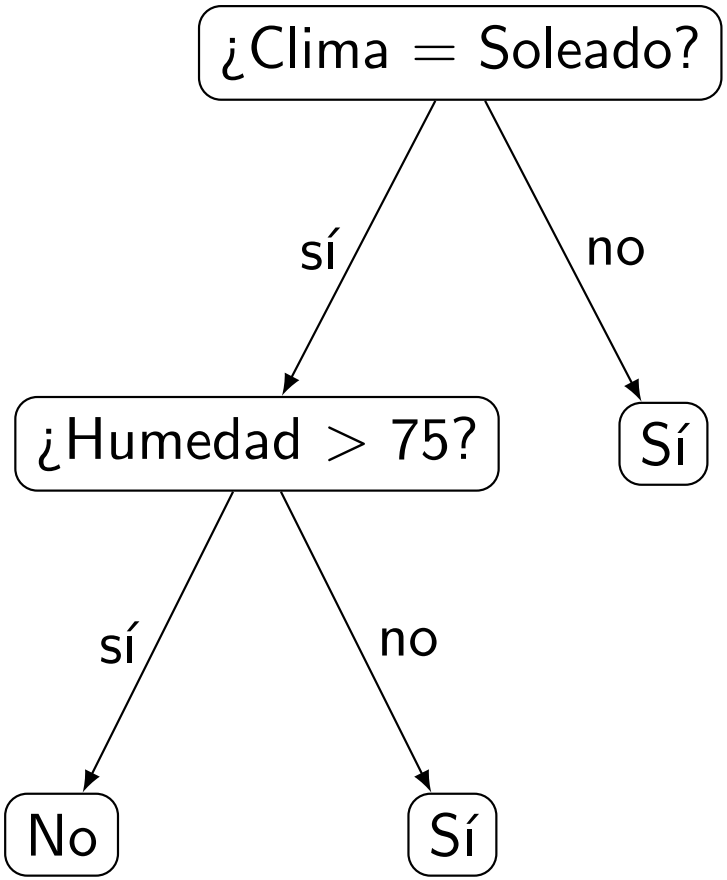

Figura: Árbol de clasificación

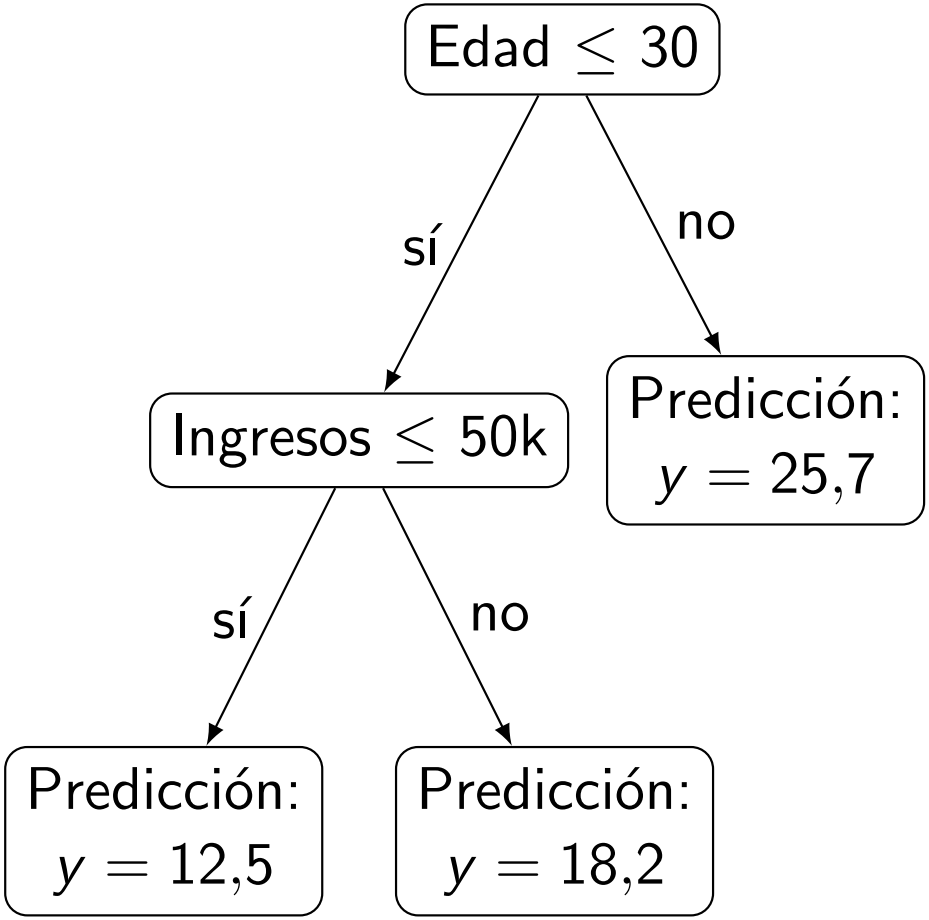

Figura: Árbol de regresión

Ventajas

- Fácil de interpretar
- Coste computacional bajo (logarítmico)
- Pueden manejar tanto variables categóricas como numéricas
- No requieren normalización de datos
- Funcionan para problemas multiclase
- Pueden validarse con técnicas estadísticas (validación cruzada)

Desventajas

- Propensos al sobreajuste
- Pueden ser inestables
- Encontrar el árbol óptimo es un problema NP-completo
- Pueden ser sesgados si las clases están desbalanceadas
- No extrapolan bien

Formulación del algoritmo

- $x_i \in \mathbb{R}^n,\ i = 1, \ldots, l$ vectores de características,
- $y \in \mathbb{R}^l$ vector de etiquetas,
- Q_m el conjunto de muestras en el nodo m,
- n_m el número de muestras en el nodo m.
- $\theta = (j, t_m)$ el parámetro de división, con la característica j y t_m es el valor de corte del nodo m.

Formulación del algoritmo

Algoritmo de construcción de árboles de decisión

1. Para cada θ, dividir Q_m en dos subconjuntos: $Q_{\text{izq}}(\theta) = \{x \in Q_m : x_j \leq t_m\}$ y $Q_{\text{dcha}}(\theta) = Q_m \setminus Q_{\text{izq}}(\theta)$.
2. La calidad de la división se evalúa con una función de impureza H

$$G(Q_m, \theta) = \frac{n_m^{\text{izq}}}{n_m} H(Q_{\text{izq}}(\theta)) + \frac{n_m^{\text{dcha}}}{n_m} H(Q_{\text{dcha}}(\theta))$$

3. Seleccionar $\theta^* = \arg\min_\theta G(Q_m, \theta)$.
4. Repetir el proceso recursivamente para cada nodo hijo.

Criterios de clasificación

Si la variable objetivo toma valores $0, 1, \ldots, k-1$, sea

$$p_{mk} = \frac{1}{n_m} \sum_{y \in Q_m} \chi_{\{y=k\}}$$

la proporción de muestras de la clase k en el nodo m.

Índice Gini

$$H(Q_m) = \sum_k p_{mk}(1 - p_{mk}) = 1 - \sum_k p_{mk}^2$$

Entropía

$$H(Q_m) = -\sum_k p_{mk} \log(p_{mk})$$

Coste computacional

Separador	**Coste de entrenamiento**	**Coste de inferencia**
Aleatorio	$\mathcal{O}(n_{\text{caract}}\, n_{\text{muestras}}^2)$	$\mathcal{O}(\log(n_{\text{muestras}}))$
Óptimo	$\mathcal{O}(n_{\text{caract}}\, n_{\text{muestras}}^2 \log(n_{\text{muestras}}))$	$\mathcal{O}(\log(n_{\text{muestras}}))$

Ejemplo simple

Sale a correr	Monta en bicicleta	Edad	Compra bebida isotónica
Sí	Sí	7	No
Sí	No	12	No
No	Sí	18	Sí
No	Sí	35	Sí
Sí	Sí	38	Sí
Sí	No	50	No
No	No	83	No

Cuadro: Ejemplo de dataset

Ejemplo simple

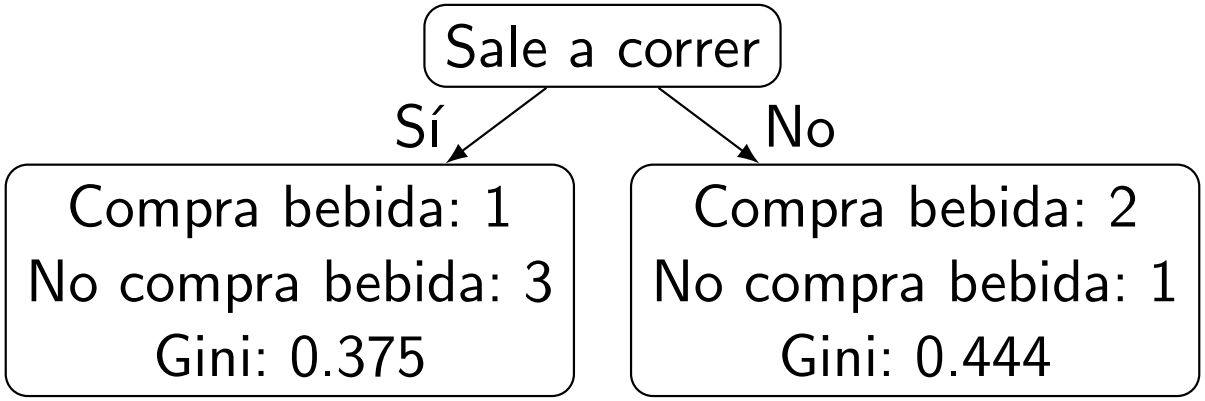

Gini total: 0.405

Ejemplo simple

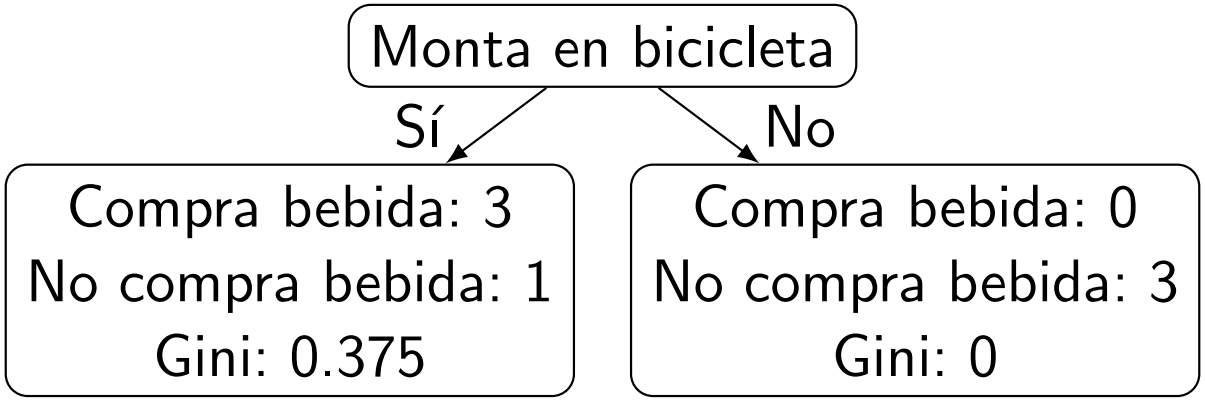

Gini total: 0.214

Ejemplo simple

Sale a correr	**Monta en bicicleta**	**Edad**	**Compra bebida isotónica**
Sí	Sí	7	No
Sí	No	12	No
No	Sí	18	Sí
No	Sí	35	Sí
Sí	Sí	38	Sí
Sí	No	50	No
No	No	83	No

Ejemplo simple

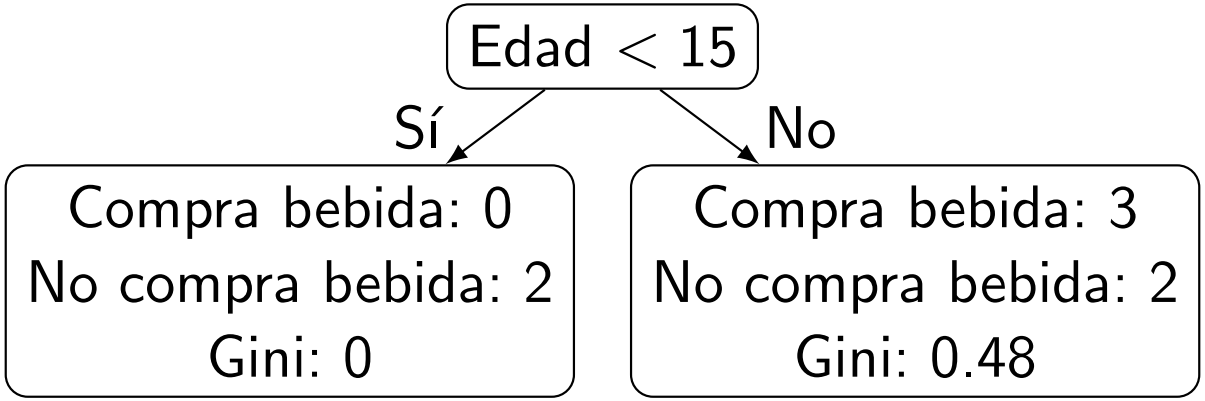

Gini total: 0.343

Ejemplo simple

Como el nodo que divide según **Monta en bicicleta** tiene menor Gini total, se selecciona esa división.

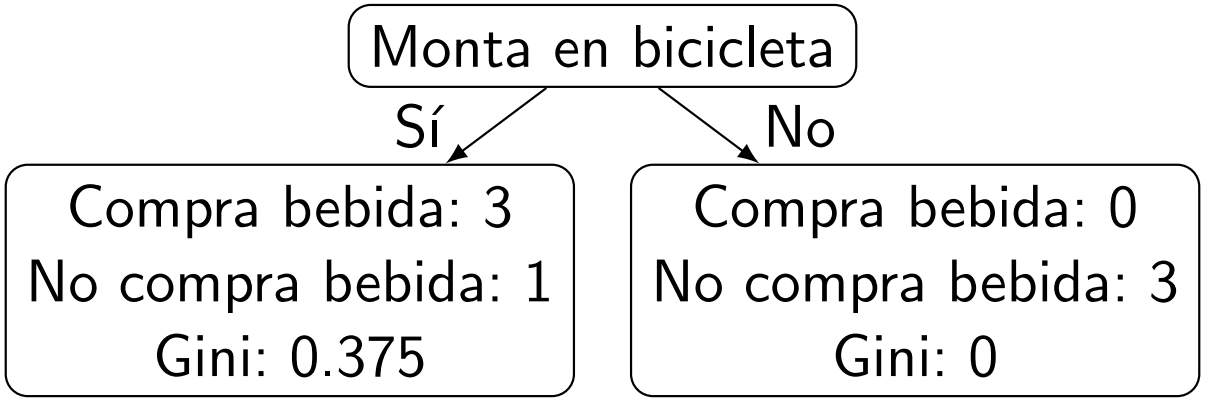

Ejemplo simple

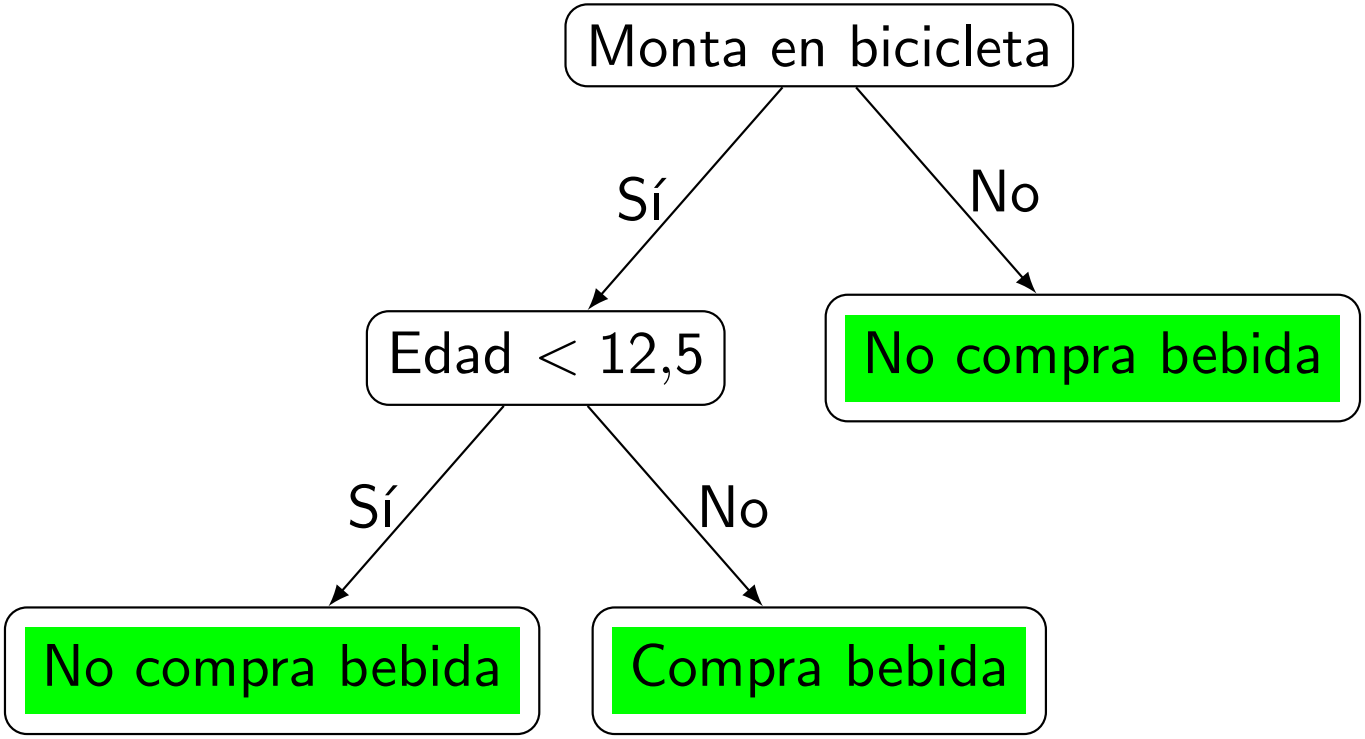

DecisionTreeClassifier (Scikit-learn)

```
class sklearn.tree.DecisionTreeClassifier (*,
    criterion='gini', splitter='best', max_depth=
    None, min_samples_split=2, min_samples_leaf=1,
    min_weight_fraction_leaf=0.0, max_features=None
    , random_state=None, max_leaf_nodes=None,
    min_impurity_decrease=0.0, class_weight=None,
    ccp_alpha=0.0, monotonic_cst=None)
```

Entrenamiento:

```
clf = DecisionTreeClassifier()
clf.fit(X_train, y_train)
```

Parámetros de DecisionTreeClassifier

- criterion: {'gini', 'entropy', 'log_loss'}, default='gini'
- splitter: {'best', 'random'}, default='best'
- max_depth: int, default=None
- min_samples_split: int, default=2
- min_samples_leaf: int, default=1
- max_features: int or float, default=None
- random_state: int, RandomState instance or None, default=None
- max_leaf_nodes: int, default=None
- min_impurity_decrease: float, default=0.0
- class_weight: dict, list of dicts, 'balanced' or None, default=None
- ccp_alpha: non-negative float, default=0.0
- monotonic_cst: list of int, default=None

Overfitting

- Criterios de parada: `max_depth`, `min_samples_split`, `min_samples_leaf`, `max_leaf_nodes`
- Poda del árbol: `ccp_alpha`
- Ensemble methods: Bagging, Boosting, Random Forests

Algunos algoritmos de árboles de decisión

- ID3
- C4.5
- CART
- Random Forests

Metodología y reparto de trabajo

Metodología: Trabajo colaborativo mediante reuniones presenciales y sesiones en Microsoft Teams. Aunque el trabajo final fue consensuado por el grupo, se dividieron las tareas de forma individual:

Teoría y presentación

- **Raúl:** Tipos de árboles, funcionamiento y diseño de diapositivas.
- **Juan:** Teoría general, algoritmos y diseño de diapositivas.

Desarrollo técnico

- **Marta e Inés:** Implementación y desarrollo del código.

- **Referencias:** Documentación de *Scikit-Learn*, artículos web y notas adicionales de Davide.

Referencias I

[1] StatQuest with Josh Starmer. *Decision and Classification Trees, Clearly Explained!!!* YouTube video. URL: https://www.youtube.com/watch?v=_L39rN6gz7Y (visitado 21-03-2026).

[2] Yury Kashnitsky. *Topic 3. Decision Trees and kNN*. Kaggle Notebook. 2021. URL: https://www.kaggle.com/code/kashnitsky/topic-3-decision-trees-and-knn (visitado 18-03-2026).

[3] Normalized Nerd. *Decision Tree Classification Clearly Explained!* YouTube video. URL: https://www.youtube.com/watch?v=ZVR2Way4nwQ (visitado 21-03-2026).

Referencias II

[4] scikit-learn developers. *1.10. Decision Trees*. scikit-learn User Guide. 2025. URL: https://scikit-learn.org/stable/modules/tree.html (visitado 18-03-2026).

[5] scikit-learn developers. *DecisionTreeClassifier*. scikit-learn API Reference. 2025. URL: https://scikit-learn.org/stable/modules/generated/sklearn.tree.DecisionTreeClassifier.html#sklearn.tree.DecisionTreeClassifier (visitado 18-03-2026).